

Proyecto Big Data en Hadoop

El presente documento, presenta un ejemplo de cómo diseñar y construir un proyecto Big Data, usando Hadoop

Objetivo del documento

Ilustrar como diseñar y construcción de una plataforma BigData, que permita el almacenamiento, procesamiento y consulta de información estructurada en Hadoop, en base a los requerimientos de un enunciado

Tecnologías

- HDFS.
- MapReduce.
- Sqoop.
- Pig.
- Hive.
- Impala

Caso

Tenemos una empresa que ofrece productos de minoristas a través de su página web, esta se encarga de gestionar los pedidos y envió a través de empresas externas de reparto, se le solicita lleva toda la información que se encuentra en sus bases de datos tradicionales (almacenes de datos) a una plataforma de BigData, el objetivo de esto es reducir el tiempo que se requiere para generar los distintos informes que la empresa necesita, cabe señalar que la empresa tiene diferentes departamentos, cada uno de ellos tiene diferentes necesidades en cuanto a sus reportes:

- Departamento ventas, este requiere ver un informe diario que le permita la evolución de las ventas, para poder definir una estrategia basada en los productos y clientes de mayor relevancia, entre las métricas que desean obtener se encuentran:
 - Categorías más vendidas.
 - Minoristas que entregan más beneficios.
 - Evolución de las ventas.
- Departamento calidad, requieren conocer la satisfacción de los usuarios en todo momento para de esta forma lograr detectar las posibles causas de insatisfacción, entre las métricas que desean obtener se encuentran:
 - Principales causas de insatisfacción.
 - Productos con mayor insatisfacción.
 - Rutas de reparto con mayor número de quejas.
- Departamento logístico, requiere detectar las rutas de reparto que causas mayor conflicto, para con ello, poder entender cómo mejorar las entregas, entre las métricas que desean obtener se encuentran:
 - Donde hay más retrasos
 - Que empresas acumulan más retrasos.
 - Como mejorar la satisfacción del cliente.

Solución propuesta para el caso

Se propone como solución gestionar un clúster basado en hadoop, el cual almacenará los datos de las bases de datos en el sistema de archivo HDFS, en cuanto a los informes se propone generarlos mediante consultas SQL a Hive e Impala

Para ello se debe:


- Identificar que tablas se deben volcar.
- Crear los procesos batch para la ingesta de datos
- Generar los informes

En base a lo anterior el presente ejemplo considera:

- Definir estructura de directorio en HDFS
- Importar los datos con Sqoop (investigación)
- Procesar con MapReduce y Pig
- Planificar con Oozie (investigación)
- Consultas con Hive e impala

Definir estructura de directorio en HDFS

Para el caso anteriormente enunciado se utilizará un DataSet de ejemplo, proporcionado “Olist”




Fuente: "Brazilian E-Commerce Public Dataset by Olist" (100.000 pedidos realizados entre 2016 y 2018)


Es posible que algunos de los archivos ya los hayamos usado en ejemplos anteriores, por ende, te recomiendo que desde tu máquina virtual de Cloudera descargues el archivo con los datos necesarios para este caso, utiliza esta url:

https://github.com/dataworldcampus/hadoop_course/archive/master.zip

Una vez hayas descargado el archivo, revisa la carpeta de descargas, luego descomprime el archivo, luego mueve el directorio obtenido “hadoop_course-master” hasta tu “workspace” verás algo similar



Ingresa en hasta el directorio data, para ello sigue la siguiente ruta “/home/cloudera/workspace/hadoop_course-master/datawarehouse/data” en el encontrarás los archivos csv con el almacén de datos que se usarán para este caso ejemplo



Copia los archivos al HDFS, puedes hacerlo a través de HUE por interfaz gráfica o por línea de comando tal como se puede ver a continuación, cabe señalar que el directorio “caso_ejemplo”, ya está creado en HDFS, si no lo tienes créalo.

```
[cloudera@quickstart data]$ cd /home/cloudera/workspace/hadoop_course-master/datawarehouse/data/
[cloudera@quickstart data]$ ll
total 63364
-rw-rw-r-- 1 cloudera cloudera 9033957 Jan 3 2020 customers_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 15438671 Jan 3 2020 order_items_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 5777138 Jan 3 2020 order_payments_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 14409007 Jan 3 2020 order_reviews_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 17654914 Jan 3 2020 orders_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 2613 Jan 3 2020 product_category_name_translation.csv
-rw-rw-r-- 1 cloudera cloudera 2379446 Jan 3 2020 products_dataset.csv
-rw-rw-r-- 1 cloudera cloudera 174703 Jan 3 2020 sellers_dataset.csv
[cloudera@quickstart data]$ hadoop fs -put /home/cloudera/workspace/hadoop_course-master/datawarehouse/data/* /user/cloudera/
caso ejemplo
```

Procesar con MapReduce y Pig

Para el siguiente ejemplo utilizaremos el archivo “order_reviews_dataset.csv”, utilizando un script pig el cual contará las palabras de cada opinión y las ordenará por frecuencia.

```
-- Lee fichero usando PigStorage, especificar como estructurar los datos de entrada
-- En este caso es un csv con campos separados por comas
csv_data = LOAD '/user/cloudera/MapReduce/data/order_reviews_dataset.csv' USING PigStorage(',') as (review_id:chararray, order_id:chararray, sc

-- Hacemos un volcado para ver los resultados
DUMP csv_data;

-- Seleccionamos la característica que analizaremos
comentarios = FOREACH csv_data GENERATE $4;

-- Hacemos un volcado para ver los resultados
DUMP comentarios;

-- accedemos a cada palabra del comentario
-- TOKENIZE: parte una cadena en una grupo de palabras
-- FLATTEN: desanida tuplas y grupo de palabras
wordfile_flat = FOREACH comentarios GENERATE FLATTEN(TOKENIZE($0)) as wordin;

-- Agrupamos por palabra
wordfile_grpd = GROUP wordfile_flat by wordin;


-- Calculamos la frecuencia
word_counts = FOREACH wordfile_grpd GENERATE group, COUNT(wordfile_flat.wordin) as cnt;

-- Ordenamos las palabras en orden de frecuencia DESC
word_counts_des = ORDER word_counts BY cnt DESC;

-- Escribimos en HDFS
STORE word_counts_des into '/user/cloudera/pig_wordcount/out';
```

Cabe señalar que es el mismo archivo que se propuso en la clase 07, el cual se encuentra disponible bajo el nombre “wordcount.pig”

Con esto en consideración vayamos a la máquina virtual para ejecutar este ejemplo, primero habrá en su explorador de archivo la siguiente ruta /home/cloudera/workspace/hadoop_course-master/pig/wordcount



Este directorio contiene los siguientes archivos:

- 0_preparar_hdfs.sh, contiene un script que un comando que copie el fichero de opiniones a HDFS.
- 1_run_pig.sh, contiene un script que lanza el script “wordcount.pig”
- 2_ver_resultado.sh, contiene un script muestra los primeros 100 registros obtenidos.
- 3_borrar_dir_salida.sh, contiene un script que borra los directorios y archivos de salida.
- wordcount.pig


Revise cada uno de los archivos, ya que tienen comentarios que te pueden ayudar a entenderlos, luego lanza los scripts.

```
File Edit View Search Terminal Help
[cloudera@quickstart pig]$ chmod 777 wordcount/
[cloudera@quickstart pig]$ cd wordcount/
[cloudera@quickstart wordcount]$ ll
total 20
-rw-rw-r-- 1 cloudera cloudera 275 Jan 3 2020 0_preparar_hdfs.sh
-rw-rw-r-- 1 cloudera cloudera 662 Jan 3 2020 1_run_pig.sh
-rw-rw-r-- 1 cloudera cloudera 233 Jan 3 2020 2_ver_resultado.sh
-rw-rw-r-- 1 cloudera cloudera 205 Jan 3 2020 3_borrar_dir_salida.sh
-rw-rw-r-- 1 cloudera cloudera 1033 Jan 3 2020 wordcount.pig
[cloudera@quickstart wordcount]$ chmod 777 0_preparar_hdfs.sh
[cloudera@quickstart wordcount]$ chmod 777 *
[cloudera@quickstart wordcount]$ ll
total 20
-rwxrwxrwx 1 cloudera cloudera 275 Jan 3 2020 0_preparar_hdfs.sh
-rwxrwxrwx 1 cloudera cloudera 662 Jan 3 2020 1_run_pig.sh
-rwxrwxrwx 1 cloudera cloudera 233 Jan 3 2020 2_ver_resultado.sh
-rwxrwxrwx 1 cloudera cloudera 205 Jan 3 2020 3_borrar_dir_salida.sh
-rwxrwxrwx 1 cloudera cloudera 1033 Jan 3 2020 wordcount.pig
[cloudera@quickstart wordcount]$ ./0_preparar_hdfs.sh
put: '/user/cloudera/datawarehouse/': No such file or directory
[cloudera@quickstart wordcount]$ hadoop fs -mkdir /user/cloudera/datawarehouse/
[cloudera@quickstart wordcount]$ ./0_preparar_hdfs.sh
```

```
File Edit View Search Terminal Help
[cloudera@quickstart wordcount]$ ll
total 24
-rwxrwxrwx 1 cloudera cloudera 275 Jan 3 2020 0_preparar_hdfs.sh
-rwxrwxrwx 1 cloudera cloudera 662 Jan 3 2020 1_run_pig.sh
-rwxrwxrwx 1 cloudera cloudera 233 Jan 3 2020 2_ver_resultado.sh
-rwxrwxrwx 1 cloudera cloudera 205 Jan 3 2020 3_borrar_dir_salida.sh
-rw-rw-r-- 1 cloudera cloudera 3199 Sep 29 16:07 pig_1727651178750.log
-rwxrwxrwx 1 cloudera cloudera 1033 Jan 3 2020 wordcount.pig
[cloudera@quickstart wordcount]$ ./2_ver_resultado.sh
produto 9727
o 9650
e 9478
do 7653
de 6846
a 6020
não 4806
prazo 4580
que 4556
antes 3970
muito 3894
Produto 3770
O 3456
com 3418
no 3085
entrega 2892
chegou 2739
recebi 2664
foi 2641
bom 2576
é 2486
entregue 2468
um 2426
da 2201
em 1938
veio 1781
Muito 1768
para 1742
bem 1720
na 1662
```

Consultas con Hive e impala


Ahora acceda al editor de impala y cree una nueva base de datos a la que denominaremos “caso_ejemplo”




Acceda a la base de datos creada, y genere una tabla los archivos cargados anteriormente, para efectos de este ejemplo, omita crear una tabla con los archivos:

- order_reviews_dataset.csv
- product_category_name_translation.csv

Recuerde que la forma de crear las tablas fue vista en clases anteriores, revise la PPT clase 07, tras ello obtendrá algo similar a esto.



Para resolver las preguntas que se han realizado al inicio del enunciado, puede revisar las consultas que ya se nos proporcionan junto con los datos, para ello en navegue hasta el directorio /home/cloudera/workspace/hadoop_course-master/datawarehouse/queries y revise los archivos “consultas.sql” y “consultas2.sql”




Analízalas y úselas en su editor “Impala”, a continuación ejemplo

A screenshot of the Impala SQL editor interface. The top status bar shows '0.39s' and 'caso_ejemplo text'. The query editor contains the following SQL code:

```
1 -- Ingresos en funcion del mes
2 SELECT month(orders.order_purchase_timestamp) mes,
3 round(sum(order_items.price)) ingresos
4 FROM orders dataset as orders
5 join order_items_dataset as order_items on orders.order_id=order_items.order_id
6 GROUP BY mes
7 ORDER BY ingresos DESC;
```

The results pane below shows a table with two columns: 'mes' and 'ingresos'. The table contains 7 rows of data.

	mes	ingresos
1	5	1502589
2	8	1428658
3	7	1393539
4	3	1357558
5	4	1356575
6	6	1298163
7	2	1091482



Revise el resto de las consultas, experimente las diferentes visualizaciones, responda las diferentes preguntas que se plateaban al principio.